

模型	Top-1 验证误差 (%)	Top-5 验证误差 (%)	参数量 (约)	FLOPs (...)
VGG-16 / VGG-19 (参考)	≈28.0	≈9.3	≈144M	≈19.6×10 ⁹
ResNet-152	≈21.4	≈5.7	≈60M	≈11.3×10 ⁹
Inception-v3	≈21.2	≈5.6	≈24M	≈5–6×10 ⁹
Inception-v4	≈20.0	≈5.0	≈42–43M	≈12–13×10 ⁹
Inception-ResNet-v2	≈19.9	≈4.9	≈55–56M	≈12–13×10 ⁹

inception v4 论文指出一开始用sgd优化器但是后面发现rmsprop最好
还有四项基本原则## 1. 避免表征瓶颈（Avoid Representational Bottlenecks）

核心思想：信息流应当像“缓坡”而不是“悬崖”。

- **解释：** 网络在前几层提取的是原始图像特征。如果你在网络的前端突然大幅度减少特征图的尺寸（例如通过步长很大的池化或极少数量的卷积核），就会造成**信息丢失**。这种丢失是无法挽回的，因为后续层只能在残缺的信息基础上工作。
- **直观理解：** 想象你在读一本长篇小说，但第一章就被撕掉了 90% 的内容。即使你后面读得再仔细，也很难完全理解整个故事。
- **实践建议：** 特征图的维度（宽、高、通道数）应该**平滑、缓慢地减小**。

2. 高维表征更易于局部处理（Higher Dimensional Representations）

核心思想：特征越多，越容易被“拆解”和“训练”。

- **解释：** 在网络内部增加激活值的维度（即增加通道数/Filter 数量），可以让特征之间更加**解耦（Decoupled）**。如果维度太低，网络必须强行把多种信息挤在一起，这会增加学习的难度。
- **直观理解：** 让你用“颜色”和“形状”两个维度描述水果，你可能很难区分红苹果和红西红柿。但如果你增加“硬度”、“纹理”等维度，区分它们就会变得轻而易举。
- **结果：** 增加宽度可以加快收敛速度，因为梯度更容易在这些解耦的特征中流动。

3. 空间聚合前可以先降维（Spatial Aggregation on Lower Dimensional Embeddings）

核心思想：相邻像素是有冗余的，压缩一下再处理也不迟。

- **解释：** 在进行昂贵的 3×3 或 5×5 卷积之前，先用 1×1 卷积减少通道数。之所以能这么做，是因为图像中相邻的像素点高度相关。即使在降维过程中丢失了一点点信息，后续的空间聚合（卷积）也能补偿回来。
 - **直观理解：** 在进行复杂的结构分析前，先做一份“精简版摘要”。因为原始数据里有很多重复信息，摘要并不会让你错过大局。
 - **意义：** 这是 **Inception 架构的核心**，它极大地减少了计算量，让你能用同样的算力跑更深的网络。
-

4. 平衡网络的宽度和深度（Balance Width and Depth）

核心思想：不要“偏科”，资源要合理分配。

- **解释：** * **深度（Depth）：** 网络的层数。
 - **宽度（Width）：** 每层的卷积核（通道）数量。
- 单纯增加深度或单纯增加宽度，收益都会边际递减。最好的做法是**等比例地增加两者**。
- **直观理解：** 盖房子时，你不能只盖一个 100 层高但只有 1 米宽的细塔，也不能盖一个只有 1 层但占地万亩的大平层。只有长宽比例协调，空间利用率才最高。
- **结论：** 在有限的计算预算（FLOPs）下，平衡分配资源能获得最高质量的模型。
两种纯inception模块：
 - **Same 填充：** 图中未标有“V”的所有卷积均采用 Same 填充，即输出网格尺寸与输入匹配。
 - **Valid 填充：** 标有“V”的卷积采用 Valid 填充，这意味着每个单元的输入补丁完全包含在前一层中，输出激活图的网格尺寸会相应缩小。
- 残差缩放 (Scaling of the Residuals) 我们也发现，如果滤波器数量（指的是卷积的输出通道数）超过 1000，残差变体在训练初期就会出现不稳定现象，网络会直接“崩溃”（即平均池化前的最后一层在迭代几万次后仅产生零值）。解决方法：降低学习率或增加额外的批归一化都无法防止这种情况。我们发现，在将残差添加到前一层激活值之前对其进行缩放（Scaling down），似乎可以稳定训练。缩放因子：通常我们选择 0.1 到 0.3 之间的缩放因子

我们发现，虽然残差版本收敛更快，但最终的准确率主要取决于模型的规模。

训练方法：

我们利用 **TensorFlow [1]** 分布式机器学习系统，在 20 个副本（每个副本运行在一块 **NVidia Kepler GPU** 上）上，使用随机梯度下降算法对网络进行了训练。我们早期的实验使用了衰减率为 0.9 的动量法 [13]，而我们表现最好的模型则是使用 **RMSProp [16]** 实现的，其衰减率为 0.9 和 1.0。我们使用了 0.045 的学习率，每两个周期（epoch）以 0.94 的指数速率进行衰减。模型评估是利用随时间计算出的参数运行平均值（running average）进行的。

以下是resnet论文总结

问题的背景在于加深模型深度反而导致在训练集上准确率的下降

- **普通网络 (Plain Networks)**: 我们首先评估了 18 层和 34 层的普通网络。结果显示, 较深的 34 层普通网络比更浅的 18 层普通网络具有更高的验证误差。通过对比训练过程中的误差 (图 4 左), 我们观察到了退化问题——34 层普通网络在整个训练过程中始终具有更高的训练误差, 尽管 18 层普通网络的解空间是 34 层普通网络解空间的子集。
- **残差网络 (Residual Networks)**: 接着我们评估了 18 层和 34 层的残差网络 (ResNets)。我们观察到情况发生了反转: 34 层的 ResNet 优于 18 层的 ResNet (领先 2.8%)。更重要的是, 34 层 ResNet 表现出显著较低的训练误差, 并能泛化到验证数据上。这表明退化问题在此设置下得到了很好的解决, 我们成功从增加的深度中获得了准确率收益。
- CIFAR-10 与分析 (CIFAR-10 and Analysis)

我们在 CIFAR-10 数据集上进行了更多研究, 重点关注极深网络的行为。

- **实验发现**: 随着深度增加, 普通网络遭受了训练误差上升的问题。而我们的 ResNets 成功克服了优化难题, 并随深度增加展现出准确率提升。
- **110 层与 1202 层模型**: 我们成功训练了 110 层的 ResNet, 它收敛良好并达到了 6.43% 的误差率。我们进一步探索了超过 1000 层的模型 (1202 层), 该模型虽无优化困难且训练误差极低 ($<0.1\%$), 但测试结果 (7.93%) 不如 110 层模型, 我们认为这是由于在该小数据集上过拟合导致的。
- **层响应分析**: 分析显示 ResNets 的响应标准差 (std) 通常比普通网络更小。这支持了我们的基本动机, 即残差函数通常比非残差函数更接近于零。

以下是vgg论文解读

训练 (Training)

训练过程大致遵循 Krizhevsky 等人的方法。具体而言, 训练是通过使用带有动量的小批量梯度下降 (Mini-batch Gradient Descent) 来优化多项逻辑回归目标函数。

- **超参数**: 批量大小 (Batch size) 设为 256, 动量 (Momentum) 为 0.9。
- **正则化**: 通过权重衰减 (L_2 惩罚项倍数设为 $5 \cdot 10^{-4}$) 和针对前两个全连接层的丢弃法 (Dropout 比例设为 0.5) 进行正则化。
- **学习率**: 初始设为 10^{-2} , 当验证集准确率不再提高时, 学习率降低 10 倍。总共降低了 3 次, 在 37 万次迭代 (74 个 epoch) 后停止训练。

-瓶颈:

作者指出, 当网络的深度达到 **19 个权重层** (即配置 E) 时, 架构的错误率已经趋于**饱和 (Saturates)**。